

**AÇIK UÇLU ÖĞRENCİ SINAVLARININ LLM İLE
OTOMATİK DEĞERLENDİRİLMESİ: BİYOLOJİ
DERSİ ÖRNEĞİ**

**2026
BİLGİSAYAR MÜHENDİSLİĞİ
BİTİRME PROJESİ TEZİ**

Umut Toprak AKTÜRK

**AÇIK UÇLU ÖĞRENCİ SINAVLARININ LLM İLE OTOMATİK
DEĞERLENDİRİLMESİ: BİYOLOJİ DERSİ ÖRNEĞİ**

Umut Toprak AKTÜRK

**Karabük Üniversitesi
Bilgisayar ve Bilişim Bilimleri Fakültesi
Bilgisayar Mühendisliği Bölümünde
Bitirme Projesi Tezi
Olarak Hazırlanmıştır.**

KARABÜK

Haziran 2026

Umut Toprak AKTÜRK tarafından hazırlanan “AÇIK UÇLU ÖĞRENCİ
SINAVLARININ LLM İLE OTOMATİK DEĞERLENDİRİLMESİ: BİYOLOJİ
DERSİ ÖRNEĞİ” başlıklı bu projenin Bitirme Projesi Tezi olarak uygun olduğunu
onaylarım.

Doç. Dr. Yasin ORTAKÇI

.....

Bitirme Projesi Danışmanı, Bilgisayar Mühendisliği Bölümü

Bilgisayar Yazılımı Ana Bilim Dalı

...../...../2026

Bilgisayar Mühendisliği bölümü , bu tez ile, Bitirme Projesi Tezini onamıştır

Doç. Dr. Nesrin AYDIN ATASOY

.....

Bölüm Başkanı

“Bu projedeki tüm bilgilerin akademik kurallara ve etik ilkelere uygun olarak elde edildiğini ve sunulduğunu; ayrıca bu kuralların ve ilkelerin gerektirdiği şekilde, bu çalışmadan kaynaklanmayan bütün atıfları yaptığımı beyan ederim.”

Umut Toprak AKTÜRK

ÖZET

Bitirme Projesi Tezi

AÇIK UÇLU ÖĞRENCİ SINAVLARININ LLM İLE OTOMATİK DEĞERLENDİRİLMESİ: BİYOLOJİ DERSİ ÖRNEĞİ

Umut Toprak AKTÜRK

Karabük Üniversitesi

Bilgisayar ve Bilişim Bilimleri Fakültesi

Bilgisayar Mühendisliği Bölümü

Tez Danışmanı:

Doç. Dr. Yasin ORTAKÇI

Haziran 2026, 38 sayfa

Açık uçlu sınavların değerlendirilmesi eğitimciler için zaman alıcı ve subjektif bir süreçtir. Bu çalışma, açık uçlu öğrenci cevaplarını otomatik olarak puanlayan ve analiz eden bütüncül bir hibrit sistem önermektedir. Sistem, Büyük Dil Modellerinin (LLM) anlamsal kavrayış yeteneğini, Türkçe SBERT modeli ve Tesseract OCR teknolojisiyle birleştirmektedir. Çalışmada hücre biyolojisi ve hücre bölünmesi, enerji metabolizması ve moleküler genetik konularını kapsayan biyoloji müfredatına odaklanılmıştır. Sistemin eğitiminde kullanılan veri seti, 12 farklı cevap senaryosuna sahip 1116 öğrenci cevabından oluşmaktadır. Geliştirilen yaklaşımda Qwen3-4B

-Instruct, Qwen2.5-3B-Instruct ve OpenLLaMA-3B modelleri üzerinde ince ayar yapılmıştır. Ayrıca SBERT modeli ile soruların, cevapların ve doğru cevapların embeddingleri üretilmiş, bunların anlamsal benzerlik skorları kosinüs benzerliği ile eğitim verisine öznitelik olarak eklenmiştir. Sonuçlar, SBERT öznitelikleri kullanılan ince ayarlı Qwen3-4B-Instruct modelinin 3,55 perplexity, 0,16 MAE, 0,5198 BERTScore F1 ve %100 format uyumu ile en yüksek performansı gösterdiğini ortaya koymuştur. Bulgular, düşük parametrelili açık kaynaklı modellerin, teknik terminoloji yoğun biyoloji sorularında ince ayar ve semantik özellik mühendisliği ile etkili bir otomatik değerlendirme aracı olabileceğini göstermektedir.

Anahtar Sözcükler : Otomatik cevap değerlendirme, LLM fine-tuning, SBERT, LoRA, Tesseract OCR, Biyoloji eğitimi

ABSTRACT

Senior Project Thesis

AUTOMATED ASSESSMENT OF OPEN-ENDED STUDENT EXAMS USING LLM: A BIOLOGY COURSE EXAMPLE

Umut Toprak AKTÜRK

Faculty of Computer and Information Sciences

Department of Computer Engineering

Project Supervisor:

Assoc. Prof. Dr. Yasin ORTAKÇI

June 2026, 38 pages

Evaluating open-ended exams is a time-consuming and subjective process for educators. This study proposes a holistic hybrid system that automatically scores and analyzes open-ended student responses. The system combines the semantic comprehension capabilities of Large Language Models (LLMs) with the Turkish SBERT model and Tesseract OCR technology. The study focuses on the biology curriculum covering cell biology and cell division, energy metabolism, and molecular genetics. The dataset used to train the system consists of 1116 student responses with 12 different response scenarios. The developed approach involves fine-tuning the

Qwen3-4B-Instruct, Qwen2.5-3B-Instruct, and OpenLLaMA-3B models. Furthermore, embeddings of questions, answers, and correct answers were generated using the SBERT model, and their semantic similarity scores were added as features to the training data using cosine similarity. The results showed that the finely tuned Qwen3-4B-Instruct model using SBERT features demonstrated the highest performance with 3,55 perplexity, 0,16 MAE, 0,5198 BERTScore F1, and 100% format fit. The findings suggest that low-parameter open-source models, with fine-tuning and semantic feature engineering, can be an effective automated assessment tool for biology questions with a high density of technical terminology.

Key Words : Automated response evaluation, LLM fine-tuning, SBERT, LoRA, Tesseract OCR, Biology education.

TEŞEKKÜR

Bu tez çalışmasının planlanmasında, araştırılmasında, yürütülmesinde, oluşumunda ilgi ve desteğini esirgemeyen, engin bilgi ve tecrübelerinden yararlandığım, yönlendirme ve bilgilendirmeleriyle çalışmamı bilimsel temeller ışığında şekillendiren sayın hocam Doç. Dr. Yasin ORTAKÇI'ya sonsuz teşekkürlerimi sunarım.

İÇİNDEKİLER

ÖZET.....	iv
ABSTRACT.....	vi
TEŞEKKÜR.....	viii
İÇİNDEKİLER.....	ix
ŞEKİLLER DİZİNİ.....	x
ÇİZELGELER DİZİNİ.....	xi
KISALTMALAR.....	xii
BÖLÜM 1.....	1
GİRİŞ.....	1
1.1 PROBLEMİN TANIMI VE AMACI.....	1
1.2. ARAŞTIRMA SORULARI:.....	2
1.3. ÇALIŞMANIN KATKILARI:.....	3
BÖLÜM 2.....	5
LİTERATÜR TARAMASI.....	5
BÖLÜM 3.....	10
METODOLOJİ.....	10
3.1. ALAN ODAKLI VERİ SETİ TASARIMI VE SENARYO ÇEŞİTLENDİRME.....	10
3.2. SEMANTİK ANALİZ VE ÖZELLİK MÜHENDİSLİĞİ.....	11
3.3. MODEL EĞİTİMİ VE İNCE AYAR (FINE-TUNING).....	12
3.4. OCR VE UÇTAN UCA SİSTEM ENTEGRASYONU.....	13
BÖLÜM 4.....	14
DENEYSEL BULGULAR VE ANALİZ.....	14
4.1. PERFORMANS METRİKLERİ VE KARŞILAŞTIRMA.....	14
4.2. BULGULARIN ANALİZİ.....	20
4.2.1. İnce ayarın etkisi (RQ1).....	20
4.2.2. SBERT özniteliklerinin etkisi (RQ2).....	21
4.2.3. BERTScore karşılaştırması.....	22
4.2.4. Model karşılaştırması (RQ3).....	22
4.2.5. Tutarlılık ve pratik kullanılabilirlik (RQ4).....	23
BÖLÜM 5.....	24
SONUÇLAR VE ÖNERİLER.....	24
KAYNAKLAR.....	26
ÖZGEÇMİŞ.....	28

ŞEKİLLER DİZİNİ

Şekil 4.1. Qwen3-4B-Instruct modelinin SBERT öznitelikleri eklenmemiş veri setiyle 500 adımlık eğitim sürecine ait train ve validation loss eğrileri.....	27
Şekil 4.2. Qwen2.5-3B-Instruct modelinin SBERT öznitelikleri eklenmemiş veri setiyle 500 adımlık eğitim sürecine ait train ve validation loss eğrileri.....	28
Şekil 4.3. OpenLLaMA-3B modelinin SBERT öznitelikleri eklenmemiş veri setiyle 500 adımlık eğitim sürecine ait train ve validation loss eğrileri.....	28
Şekil 4.4. Qwen3-4B-Instruct modelinin SBERT öznitelikleri eklenmiş veri setiyle 500 adımlık eğitim sürecine ait train ve validation loss eğrileri.....	29
Şekil 4.5. Qwen2.5-3B-Instruct modelinin SBERT öznitelikleri eklenmiş veri setiyle 500 adımlık eğitim sürecine ait train ve validation loss eğrileri.....	29
Şekil 4.6. OpenLLaMA-3B modelinin SBERT öznitelikleri eklenmiş veri setiyle 500 adımlık eğitim sürecine ait train ve validation loss eğrileri.....	30

ÇİZELGELER DİZİNİ

Çizelge 4.1. SBERT öznitelikleri kullanılmadan eğitilen modellerin performans karşılaştırması.....	26
Çizelge 4.2. SBERT öznitelikleri dahil edilerek eğitilen modellerin performans karşılaştırması.....	26

KISALTMALAR

AES : Otomatik Kompozisyon Puanlama (Automated Essay Scoring)

API : Uygulama Programlama Arayüzü (Application Programming Interface)

ATP : Adenozin Trifosfat

BERTScore : BERT Tabanlı Değerlendirme Metriği

EFL : Yabancı Dil Olarak İngilizce (English as a Foreign Language)

F1 : Dengeli Başarı Ölçütü / F1 Puanı

ICC : Sınıf İçi Korelasyon Katsayısı (Intraclass Correlation Coefficient)

LLM : Büyük Dil Modelleri (Large Language Models)

LoRA : Düşük Dereceli Uyarlama (Low-Rank Adaptation)

MAE : Ortalama Mutlak Hata (Mean Absolute Error)

OCR : Optik Karakter Tanıma (Optical Character Recognition)

RAG : Artırılmış Bilgi Geri Çağırma (Retrieval-Augmented Generation)

RQ : Araştırma Sorusu (Research Question)

SBERT : Cümle Tabanlı BERT (Sentence-BERT)

SFT : Denetimli İnce Ayar (Supervised Fine-Tuning)

simQS : Soru ve Öğrenci Cevabı Arasındaki Anlamsal Benzerlik Skoru (Similarity Question-Student)

simSC : Öğrenci Cevabı ve İdeal Cevap Arasındaki Anlamsal Benzerlik Skoru (Similarity Solution-Student)

BÖLÜM 1

GİRİŞ

1.1 PROBLEMİN TANIMI VE AMACI

Eğitimde açık uçlu sorular, öğrencilerin eleştirel düşünme, sentez yapma ve kendilerini ifade etme becerilerini geliştirmede vazgeçilmez bir role sahiptir (Feng, 2014). Çoktan seçmeli testlerin aksine, bu sorular öğrencinin konuyu yalnızca hatırlamasını değil, analiz, sentez ve üst düzey bilişsel süreçlerle anlamlandırmasını da değerlendirmeye olanak tanır (Bloom et al., 1956; Cullen, 1998; Greenfield et al., 2009; Kwon, Park, and Park, 2006). Ancak açık uçlu soruların manuel olarak puanlanması, özellikle kalabalık sınıflarda öğretmenler için önemli bir zaman yükü oluşturmakta ve değerlendirme sürecinde subjektiflik riskini beraberinde getirmektedir (Arffman, 2016; Livingston, 2009).

Son yıllarda Büyük Dil Modellerinin (LLM) metin anlama ve muhakeme yeteneklerindeki hızlı ilerleme, açık uçlu öğrenci cevaplarının otomatik, standart ve daha adil bir şekilde değerlendirilmesi için güçlü bir fırsat sunmaktadır (Lee & Song, 2024; Pack et al., 2024; Yavuz et al., 2025). Buna rağmen, literatürdeki çalışmaların büyük çoğunluğu yüksek parametrelili ve kapalı kaynaklı modellere odaklanırken, özellikle teknik terminoloji yoğun disiplinlerde (örneğin Biyoloji) düşük parametrelili açık kaynaklı modellerin ince ayarlı performansları ve SBERT gibi semantik özelliklerle desteklenen hibrit yaklaşımların etkinliği hâlâ önemli bir araştırma boşluğu olarak durmaktadır.

Bu çalışmanın temel amacı, öğrenci cevaplarını basit anahtar kelime eşleşmelerinin ötesinde, anlamsal derinlikleriyle kavrayabilen uçtan uca bir sınav değerlendirme sistemi geliştirmektir. Geliştirilen sistem özellikle teknik terminolojinin yoğun olduğu Biyoloji alanına (hücre biyolojisi, enerji metabolizması, moleküler genetik vb.) odaklanmıştır. Sistem, öğrenci cevaplarındaki nüansları ayırt edebilmek üzere 12 farklı cevap senaryosunu kapsayacak şekilde tasarlanmıştır. Yöntem olarak, karakter tanımda Tesseract OCR, anlamsal benzerlik ölçümünde SBERT ile embedding üretimi ve kosinüs benzerliği kullanılmıştır. Geliştirilen bu iş hattının devamında öğrenci cevaplarının doğruluğunun analizinde ve puanlamasında Qwen3-4B-Instruct-2507 (Qwen3), Qwen2.5-3B-Instruct (Qwen2.5) ve OpenLLaMA-3B (OpenLLaMA) gibi düşük parametrelili LLM'ler kullanılmıştır. Bu LLM modelleri LoRA tabanlı bir ince-ayar sürecinden geçirilmiştir. İnce-ayar sürecinde öğrencilere ait 1116 soru-cevap ve doğru cevap veri seti kullanılmıştır. Çalışmada denenen üç farklı LLM modelinin bu kapsamdaki performansları karşılaştırmalı olarak incelenmiş ve Qwen3'ün çoğunlukla bütün metriklerde diğer LLM'lere üstünlük sağladığı görülmüştür.

1.2. ARAŞTIRMA SORULARI:

Bu çalışma kapsamında, geliştirilen sistemin etkinliğini ve modellerin performansını değerlendirmek üzere aşağıdaki araştırma sorularına yanıt aranmıştır:

RQ1: Düşük parametrelili büyük dil modellerinin (Qwen3-4B, Qwen2.5-3B ve OpenLLaMA-3B), LoRA tabanlı ince-ayar (fine-tuning) süreci sonrasında biyoloji dersi açısından açık uçlu soruları değerlendirme ve puanlamadaki başarısı nedir?

RQ2: SBERT tabanlı vektör temsillerinin (embeddings) kullanımının, metinlerin LLM'lere ham veri olarak sunulduğu temel bir iş hattına kıyasla, sistemin anlamsal değerlendirme ve puanlama performansına katkısı nedir?

RQ3: Model boyutları benzer olmasına rağmen, Qwen3-4B-Instruct modelinin diğer açık kaynaklı modellere (Qwen2.5 ve OpenLLaMA) kıyasla doğruluk ve diğer performans metriklerinde istatistiksel olarak anlamlı bir üstünlük sağlamasının temel nedenleri nelerdir?

RQ4: Geliştirilen uçtan uca otomatik puanlama sistemi, manuel değerlendirme süreçlerindeki eğitimciler üzerindeki iş yükünü hafifletme potansiyeli açısından ne düzeyde bir tutarlılık sergilemektedir?

1.3. ÇALIŞMANIN KATKILARI:

Bu çalışma, açık uçlu sınavlarda öğrenci cevaplarının otomatik değerlendirilmesi alanında literatüre aşağıdaki temel katkıları sunmaktadır:

- Bu çalışma metin tanıma aşamasından başlayıp semantik analiz ve LLM puanlamasına kadar uzanan, insan müdahalesine duyulan ihtiyacı minimize eden bütüncül ve otomatik bir sınav değerlendirme çerçevesi sunulmaktadır.
- Literatürdeki çalışmaların büyük çoğunluğu GPT-4 gibi yüksek parametrelili ve kapalı kaynaklı modellere odaklanırken; bu çalışma, Qwen3, Qwen2.5 ve OpenLLaMA gibi düşük parametrelili açık kaynaklı modellerin kullanılabileceğini göstermektedir.
- Geleneksel anahtar kelime eşleştirme yöntemlerinin aksine, SBERT tabanlı embedding üretimi ile LLM tabanlı muhakeme yeteneğini birleştiren, anlamsal derinliği yüksek bir puanlama iş hattı (pipeline) önerilmektedir.

- Sistem, yalnızca "doğru/yanlış" ayrımı yapmakla kalmayıp, öğrenci cevaplarındaki nüansları yakalayabilen 12 farklı cevap senaryosunu kapsayacak şekilde tasarlanarak gerçek sınıf ortamındaki çeşitliliği modelleme başarısı göstermiştir.

BÖLÜM 2

LİTERATÜR TARAMASI

Açık uçlu öğrenci essay'lerin otomatik değerlendirilmesi uzun yıllardır üzerinde çalışmalar yapılan bir sorundur. Geleneksel yöntemler genellikle el yapımı özelliklere, kelime eşleşmesine ve klasik makine öğrenmesi tekniklerine dayanırken, son yıllarda LLM'ler bu alanda önemli ilerlemeler sağlamıştır (Atkinson & Palma, 2025) .

Literatürde modellerin ince ayar (fine-tuning) yapılmadan sadece prompt mühendisliği (prompt engineering) yöntemlerinin kullanarak yapılan çalışmalar da mevcuttur. Bu kapsamda Llama 3.1 ve Qwen gibi modeller üzerinde test edilen zero-shot, few-shot ve RAG gibi tekniklerin, üniversite ortamları için ince ayar yönteminden daha ekonomik ve sürdürülebilir bir seçenek olduğu ortaya konmuştur (Polanko, 2025) . Benzer şekilde, Pack et al. (2024) PaLM 2, Claude 2, GPT-3.5 ve GPT-4 modellerini herhangi bir ince ayar süreci olmaksızın test ederek, İngilizce dil öğrenen öğrencilerin yazma becerilerinin değerlendirilmesinde LLM'lerin geçerlilik (validity) ve güvenilirliğini (reliability) detaylıca incelemiştir. Söz konusu çalışma, GPT-4'ün insan puanlayıcılarla en yüksek korelasyonu sergileyen model olduğunu kanıtlarken; aynı zamanda modellerin zaman içindeki güncellemelerden kaynaklanan performans dalgalanmaları ve halüsinasyon riskleri gibi zayıf yönlerine de dikkat çekmektedir. Yavuz et al. (2025) yükseköğretim düzeyindeki İngilizce (EFL) kompozisyonlarının analitik bir rubrik üzerinden değerlendirilmesinde ChatGPT (GPT-4) ve Bard modellerinin geçerlilik ve güvenilirliğini, 15 uzman öğretmenin puanlarıyla karşılaştırmalı olarak analiz etmiştir. Çalışma; detaylı prompt mühendisliği ve düşük sıcaklık (temperature) ayarı ile optimize edilen modellerin, özellikle dil bilgisi ve

mekanik kurallar gibi nesnel kriterlerde insan değerlendiricilerle yüksek uyum ($ICC = 0,972$) sergilediğini, ancak içerik ve organizasyon gibi öznel alanlarda daha 'cömert' puanlar verme eğiliminde olduğunu ortaya koymuştur.

Bunlara ek olarak ince ayar yapılarak sadece puanlama değil yanında kullanıcıya feedback veren çalışmalar da mevcuttur. Xiao et al. (2025) , sadece prompt mühendisliğinin karmaşık değerlendirme kriterleri karşısında yetersiz kalabildiğine dikkat çekerek, insan bilişsel süreçlerini temel alan 'Hızlı ve Yavaş Düşünme' (dual-process) teorisine dayalı hibrit bir otomatik puanlama çerçevesi önermiştir. Bu sistemde, hızlı sayısal puanlama için hafif bir sınıflandırıcı (Fast Module) kullanılırken; derinlemesine analiz, puan gerekçelendirme ve doğal dilde geri bildirim üretimi için açık kaynaklı LLaMA3-8B modeline denetimli ince ayar (SFT) yapılması tercih edilmiştir. Araştırma sonuçları, ince ayar yapılmış açık kaynaklı modellerin hem kapalı kaynaklı rakipleriyle yarışabilecek bir performans sergilediğini hem de eğitimciler için maliyet etkin ve yüksek tutarlılık sunan bir 'iş birliği ortağı' haline geldiğini kanıtlamaktadır. Çalışmanın en dikkat çekici bulgularından biri, yapay zeka tarafından sağlanan açıklamalı geri bildirimlerin, deneyimsiz (novice) değerlendiricilerin puanlama yetkinliğini uzman (expert) seviyesine yükseltirken; uzmanların ise özellikle sistem tarafından düşük güven puanıyla işaretlenen karmaşık ödevlerde daha verimli ve tutarlı kararlar almasını sağlamasıdır.

Heydari et al. (2026) , kısa cevaplı yanıtların otomatik puanlanması ile etkileşimli geri bildirim üretimini birleştiren iki farklı mimariyi karşılaştırmalı olarak incelemiştir. Çalışmada, verimlilik odaklı yerel ince ayarlı (fine-tuned) bir GPT-2 modeli ile gelişmiş geri bildirim kalitesi sunan, GPT-4o Vision ve LLaMA-2 modellerini kullanan Artırılmış Bilgi Geri Çağırma (RAG) destekli bir API hattı test edilmiştir. Araştırma sonuçları, API tabanlı sistemin karmaşık yanıtları anlama ve zengin içerikli geri bildirim üretme konusunda daha etkili olduğunu ($R^2 = 0,920$) ortaya koymuştur. Bununla birlikte, yerel modelin veri gizliliği ve yüksek işlem hızı (saatte 2000 kağıt) gibi avantajları da göz önünde bulundurularak; rutin değerlendirmeler için yerel modellerin, yüksek kaliteli açıklama gerektiren durumlar için ise API tabanlı

sistemlerin tercih edildiđi bir hibrit strateji önerilmektedir. Söz konusu çalışma, yapay zekanın sadece bir notlandırma aracı deđil, aynı zamanda şeffaf ve açıklanabilir geri bildirimler sunan bir asistan olarak kullanım potansiyelini teknik verilerle desteklemektedir. Benzer şekilde Polanko (2025) , üniversite düzeyindeki felsefe ve ekoloji ödevlerinin deđerlendirilmesinde Llama 3.1 ve Qwen gibi açık kaynaklı modellerin, ince ayar gerektirmeyen prompt mühendisliđi teknikleriyle (zero-shot, few-shot ve RAG) kullanımını incelemiştir. Çalışmada, ince ayar yönteminin (fine-tuning) yüksek doğruluk sunmasına rağmen yüksek işlem gücü gerektirmesi ve modele sadece belirli bir görevi öğretmesi (task-specific) nedeniyle kısıtlı olduđu; buna karşın prompt mühendisliđinin düşük maliyetli ve farklı derslere hızla uyarlanabilir yapısıyla üniversite ortamları için daha sürdürülebilir bir seçenek olduđu vurgulanmaktadır. Geliştirilen sistemde, modelin nihai puana ulaşmadan önce konu geliştirme, argümantasyon ve dil bilgisi gibi altı farklı kriter üzerinden detaylı bir gerekçelendirme ürettiđi 'feedback -> score' yaklaşımı benimsenmiş; bu yöntemin hem puanlama doğruluđunu ve şeffaflıđını artırdıđı hem de öğrencilere yazma becerilerini geliştirmeleri için pedagojik bir rehber sunduđu ortaya konmuştur.

Öte yandan ince ayar yapmadan puanlama ve feedback sađlayan başka çalışmalar da literatürde mevcuttur. Örneđin, Stahl et al. (2024) , Mistral-7B modeli üzerinden kompozisyon puanlama (AES) ve geri bildirim üretimini eş zamanlı olarak gerçekleştirme stratejilerini incelemiştir. Farklı persona (öğretmen asistanı, yaratıcı yazarlık mentoru vb.) ve komut (prompt) yapılarını test eden araştırma, puanlama ile geri bildirim görevlerinin birlikte ele alınmasının, özellikle modelin puanlama başarısını artırdıđını saptamıştır. Çalışmada, modelin nihai puana ulaşmadan önce bir açıklama veya geri bildirim üretmesinin (Chain-of-Thought benzeri bir yaklaşımla), daha doğru deđerlendirmeler yapılmasına olanak tanıdıđı ortaya konmuştur. Yapılan manuel deđerlendirmeler sonucunda, sistem tarafından üretilen geri bildirimlerin netlik ve genel fayda açısından öğrenciler için yüksek bir deđer taşıdıđı belirlenmiş; ancak puanlama sürecinin geri bildirim kalitesine olan doğrudan etkisinin sınırlı kaldıđı vurgulanmıştır. Benzer şekilde güncel bir çalışmada AlGhamdi et al. (2026) , yükseköğretim düzeyindeki açık uçlu deđerlendirmelerin puanlanması ve geri

bildirim sağlanması süreçlerinde GPT-4o modelinin ince ayar gerektirmeyen prompt tabanlı kullanımı incelenmiştir. Çalışmada, puanlama ve geri bildirim görevlerinin tek bir prompt (prompt composition) veya iki ardışık prompt (prompt decomposition) şeklinde yapılandırılmasının etkileri analiz edilmiştir. Araştırma bulguları, GPT-4o tarafından üretilen geri bildirimlerin insan tarafından yazılanlara kıyasla öğrenci özerkliğini (learner agency) ve katılımını daha fazla teşvik ettiğini ortaya koymuştur. Ayrıca görev sıralamasının pedagojik sonuçlar üzerinde belirleyici olduğu; geri bildirim puanlamadan önce talep edilmesinin öğrenci bağımsızlığını güçlendirdiği, puanlamadan sonra verilmesinin ise öğretmen-öğrenci etkileşimini vurgulayan bir yapı sunduğu saptanmıştır. Puanlama başarısı açısından ise modelin, özellikle düşük kaliteli öğrenci çalışmalarında daha fazla hata yapma eğiliminde olduğu gözlemlenmiştir.

Sistemlerin performansını daha da ileriye taşımak amacıyla, LLM'lerin yeteneklerini geleneksel dilbilimsel analizlerle birleştiren hibrit yaklaşımlar da literatürde mevcuttur. Bu kapsamda Hou et al. (2025) , mevcut otomatik kompozisyon puanlama (AES) sistemlerini; yüksek performans sunan ancak yoğun kaynak ve eğitim gerektiren "denetimli özellik tabanlı yaklaşımlar" ile çıkarım aşamasında verimli olan fakat düşük performans sergileyebilen "LLM tabanlı yöntemler" olarak iki ana kategoriye ayırmaktadır. Araştırmacılar, bu iki yöntemin eksikliklerini gidermek için dilbilimsel özellikleri (linguistic features) LLM tabanlı puanlama sürecine dahil eden hibrit bir model önermişlerdir. Yapılan deneyler, bu hibrit yaklaşımın hem aynı alan (in-domain) hem de farklı alanlardaki (out-of-domain) yazma yönergelerinde temel alınan (baseline) modellerden daha yüksek bir başarı sergilediğini ortaya koymuştur. Bu çalışma, sadece modelin genel yeteneklerine güvenmek yerine, yapılandırılmış dilbilimsel verilerin sürece entegre edilmesinin çok daha esnek ve güçlü bir puanlama mekanizması oluşturduğunu kanıtlamaktadır.

Literatür incelendiğinde bu alandaki çalışmaların büyük çoğunluğu essaylar üzerine odaklanmış ve kısa açık uçlu soru cevapların değerlendirilmesindeki eksik göze çarpmaktadır. Literatürden de anlaşılacağı gibi spesifik alanlar için ince ayar işlemi modelin istenilen başarıyı sağlamasında prompt engineering'e kıyasla daha etkin başarı sağladığı görülmüştür (Polanko, 2025) . Bu çalışma ise açık kaynaklı ve düşük

parametrelili modelleri spesifik bir veri seti üzerinde fine-tune ederek literatüre katkı sağlamayı hedeflemektedir. Ayrıca, mevcut çalışmaların aksine öğrenci cevaplarını modellere ham metin formatında sunmak yerine, SBERT tabanlı embedding üretimi ile bir semantik çıkarım metodolojisi önermektedir. Son olarak; Tesseract OCR entegrasyonu sayesinde, metinlerin tanınmasından nihai puanlamaya kadar uzanan, uçtan uca ve bütüncül bir sınav değerlendirme ekosistemi sunması bakımından mevcut literatürden ayrışmaktadır.

BÖLÜM 3

METODOLOJİ

Sistemin çalışma prensibi, veri hazırlığından kullanıcı arayüzüne kadar entegre çalışan dört ana aşamadan oluşmaktadır

3.1. ALAN ODAKLI VERİ SETİ TASARIMI VE SENARYO ÇEŞİTLENDİRME

Bu çalışma kapsamında modellerin akademik muhakeme ve teknik terminolojiye hakimiyet yetenekleri, Biyoloji bilimi üzerinde test edilmiştir. Veri seti; hücre zarı ve taşıma mekanizmaları (aktif/pasif taşıma, osmoz), hücre organelleri, enerji metabolizması (ATP, enzimler), genetik moleküller, protein sentezi ve hücre bölünmesi konularını kapsayan geniş bir müfredat üzerine kurgulanmıştır.

Modelin sadece "doğru/yanlış" ayrımı yapmanın ötesine geçebilmesi amacıyla, 1116 adet (992 eğitim, 124 doğrulama) Instruct-tabanlı veri kaydı ChatGPT, Gemini ve Claude modelleri aracılığıyla sentetik olarak üretilmiştir. Veri seti 31 farklı soru ve her soru için 36 farklı cevap olacak şekilde 1116 adet cevaptan oluşmaktadır, biyoloji konuları sorulara eşit olarak dağıtılmıştır.

Veri seti, şu 12 farklı cevap senaryosunu içerecek şekilde dengelenmiştir:

- Doğruluk Dereceleri: 3 adet tam doğru, 4 adet büyük ölçüde doğru, 3 adet kısa-yüzeysel doğru, 2 adet çok kısa doğru ve 2 adet standart kısa doğru cevaplar.

- Hata ve Eksiklik Analizi: 4 adet eksik cevap, 2 adet ters (çelişkili) bilgi içeren ve 3 adet doğru ve yanlış bilgilerin karıştığı cevaplar.
- Bağlamsal ve Format Analizi: 2 adet konuyu anlatan ancak soruyu yanıtlamayan (kaçamak) cevap, 2 adet çok kısa veya 2 adet kısa yanlış cevap ve 2 adet tamamen alakasız (yanlış) cevaplar.

Nihai performans değerlendirmesi için bu kümeden tamamen bağımsız, rastgele dağılımlı 199 adetlik harici bir test seti yapılandırılmıştır.

3.2. SEMANTİK ANALİZ VE ÖZELLİK MÜHENDİSLİĞİ

LLM modellerine anlamsal bir referans noktası sağlamak amacıyla SBERT (Sentence-BERT) tabanlı bir özellik çıkarımı uygulanmıştır. emrecaan/bert-base-turkish-cased-mean-nli modeli kullanılarak her öğrenci cevabı için şu iki temel metrik kosinüs benzerliği yöntemi ile hesaplanmıştır:

- simQS (Similarity Question-Student): Öğrenci cevabının soru metni ile anlamsal benzerliği.
- simSC (Similarity Solution-Student): Öğrenci cevabının ideal "anahtar" cevap ile benzerliği.

Bu sayısal skorlar, modelin girdi (prompt) kısmına birer öznitelik (feature) olarak eklenmiştir. Bu sayede, özellikle "konuyu anlatan ama soruyu cevaplamayan" (yüksek simQS, düşük simSC) gibi teknik ayrım gerektiren karmaşık senaryoların model tarafından daha isabetli analiz edilmesi hedeflenmiştir.

3.3. MODEL EĞİTİMİ VE İNCE AYAR (FINE-TUNING)

Eğitim sürecinde bellek verimliliği ve hesaplama hızı sağlamak amacıyla **Unsloth** kütüphanesi kullanılarak Denetimli İnce-Ayar (SFT) ve LoRA (Low-Rank Adaptation) yöntemi tercih edilmiştir. LoRA ve SFT için parametre ayarlamaları şu şekilde yapılmıştır:

MAX_SEQ_LENGTH = 2048

LORA_R = 16

LORA_ALPHA = 32

LORA_DROPOUT = 0.05

MAX_STEPS = 500

LORA_TARGET_MODULES = ["q_proj", "k_proj", "v_proj", "o_proj", "gate_proj",
"up_proj", "down_proj"]

Modeller (Qwen3-4B, Qwen2.5-3B ve OpenLLaMA-3B), 4-bit kuantizasyon tekniği ile optimize edilerek Google Colab ortamında eğitilmiştir. Bu yaklaşım ile düşük parametrelili modellerin, biyoloji gibi spesifik terminoloji içeren analiz ve puanlama görevlerindeki performansları incelenmiştir.

Modellerin adil bir şekilde karşılaştırılması amacıyla tüm eğitim süreçlerinde aynı hiperparametre seti kullanılmıştır. Denetimli İnce-Ayar (SFT) yapılandırmasında; yerel paket boyutu (per-device batch size) 2, gradyan biriktirme adımı (gradient accumulation steps) 4 olarak belirlenmiş ve böylece 8'lik bir efektif global paket boyutu (global batch size) elde edilmiştir. Donanım optimizasyonu için sistemin desteklediği veri formatına göre otomatik olarak FP16 veya BF16 hassasiyeti seçilmiş; ağırlık optimizasyonunda ise bellek dostu 8-bit AdamW (adamw_8bit) optimizasyon algoritması tercih edilmiştir.

Eđitim, veri seti ölçeđi (1116 örnek) dođrultusunda yaklaşık 3,58 epoch deđerine karşılık gelen 500 maksimum adım (max_steps) ile sınırlandırılmıştır. Öğrenme oranı (learning rate) 2×10^{-4} olarak sabit tutulmuştur. Aşırı öğrenmeyi (overfitting) engellemek ve en kararlı model performansını yakalamak adına her 50 adımda bir dođrulama (validation) testi gerçekleştirilmiştir. Eđitim sonunda, dođrulama kaybı (eval_loss) deđeri en düşük olan en başarılı model kontrol noktası (checkpoint) nihai model olarak seçilmiştir.

3.4. OCR VE UÇTAN UCA SİSTEM ENTEGRASYONU

Sistem, öğrenci cevap kađıtlarının dijital görüntülerini girdi olarak kabul etmektedir. Metin çıkarma aşamasında Tesseract OCR kullanılmıştır. Mevcut teknolojilerin el yazısı üzerindeki kısıtlamaları nedeniyle, prototip aşamasında dijital ortamda oluşturulmuş net görüntüler işlenerek dođruluk payı maksimize edilmiştir. Backend altyapısı Flask ve Ngrok tünelleme ile kurgulanmış; kullanıcı deneyimi için ise React Native (Expo) tabanlı, anlık sonuç dönebilen bir mobil arayüz geliştirilmiştir.

BÖLÜM 4

DENEYSEL BULGULAR VE ANALİZ

Bu bölümde, SBERT modeliyle elde edilen embedding'lerden türetilen simQS ve simSC kosinüs benzerlik skorlarının veri setinin hem girdi hem de çıktı bölümlerine ek öznitelik olarak dahil edildiği modeller; bu özniteliklerin kullanılmadığı ham modellerle karşılaştırmalı olarak incelenmiştir. Her iki model grubu da ince ayar uygulanmış ve uygulanmamış biçimleriyle biyoloji alanına özgü test veri seti üzerinde hata payı, metin kalitesi ve tahmin tutarlılığı ölçütleri çerçevesinde değerlendirilmiştir.

4.1. PERFORMANS METRİKLERİ VE KARŞILAŞTIRMA

Modellerin başarısını ölçmek amacıyla beş temel metrik kullanılmıştır: modelin daha önce görmediği test verisi üzerindeki tahmin belirsizliğini ölçen Test Kaybı (Test Loss), bu kayıptan türetilen Perplexity, tahmin edilen puan ile gerçek puan arasındaki farkı gösteren Ortalama Mutlak Hata (MAE) ve model çıktılarının anlamsal kalitesini değerlendiren BERTScore (Precision, Recall ve F1). MAE değerleri yalnızca modelin beklenen formatta puan üretebildiği örnekler üzerinden hesaplanmış olup karşılaştırmanın sağlıklı yorumlanabilmesi için geçerli örnek sayısı (Format Uyumu) ayrıca raporlanmıştır.

Çizelge 4.1. SBERT öznitelikleri kullanılmadan eğitilen modellerin performans karşılaştırması

Model	Durum	Test Loss	Perplexity	MAE	BERTScore F1	BERTScore P	BERTScore R	Format Uyumu
Qwen3-4B-Instruct	Ham	1,9098	6,75	0,1839 *	0,4963	0,4413	0,5692	84/199
	İnce Ayarlı	1,2711	3,56	0,2395	0,5285	0,4802	0,5894	199/199
Qwen/Qwen2.5-3B-Instruct	Ham	2,2089	9,11	0,2054	0,5015	0,4698	0,5393	102/199
	İnce Ayarlı	1,6739	5,33	0,2116	0,5035	0,4740	0,5379	199/199
Open LLaMA 3B	Ham	2,1075	8,23	-	0,4619	0,4232	0,5105	0/199
	İnce Ayarlı	1,4531	4,28	0,3074	0,4803	0,4373	0,5342	47/199

**Yıldızlı MAE değeri yalnızca 84 örnek üzerinden hesaplandığından istatistiksel olarak yanıltıcıdır.*


Çizelge 4.2. SBERT öznitelikleri dahil edilerek eğitilen modellerin performans karşılaştırması.

Model	Durum	Test Loss	Perplexity	MAE	BERTScore F1	BERTScore P	BERTScore R	Format Uyumu
Qwen 3-4B-Instruct	Ham	1,9487	7,02	0,0917 *	0,4757	0,4159	0,5573	59/199
	İnce Ayarlı	1,2657	3,55	0,1635	0,5198	0,4585	0,6019	199/199
Qwen/Qwen	Ham	2,3266	10,24	0,2337	0,4836	0,4340	0,5481	119/199


2.5-3B-Instruct	İnce Ayarlı	1,5921	4,91	0,1959	0,5138	0,4521	0,5971	199/199
OpenLLaMA 3B	Ham	2,0818	8,02	-	0,4563	0,4105	0,5156	0/199
	İnce Ayarlı	1,4023	4,06	0,1928	0,5035	0,4474	0,5777	181/199

**Yıldızlı MAE değeri yalnızca 59 örnek üzerinden hesaplandığından istatistiksel olarak yanıltıcıdır.*


SBERT öznitelikleri kullanılmadan eğitilen modellerin eğitim sürecindeki yakınsama davranışları Şekil 4.1, 4.2 ve 4.3'te sunulmuştur. Eğitim süreci kapsamında, her 50 adımda bir validasyon kaybı (validation loss) hesaplanmış ve her model için bu değer en düşük olduğu adımdaki ağırlıklar kaydedilmiştir. Elde edilen bulgulara göre SBERT öznitelikleri kullanılmadan; Qwen3-4B modeli 250. adımda 0,46186, Qwen2.5-3B modeli 350. adımda 0,5791 ve OpenLLaMA-3B modeli 350. adımda 0,51843 değerleriyle en düşük validasyon kaybına ulaşmıştır.



Şekil 4.1. Qwen3-4B-Instruct modelinin SBERT öznitelikleri eklenmemiş veri setiyle 500 adımlık eğitim sürecine ait train ve validation loss eğrileri.




Şekil 4.2. Qwen2.5-3B-Instruct modelinin SBERT öznitelikleri eklenmemiş veri setiyle 500 adımlık eğitim sürecine ait train ve validation loss eğrileri.




Şekil 4.3. OpenLLaMA-3B modelinin SBERT öznitelikleri eklenmemiş veri setiyle 500 adımlık eğitim sürecine ait train ve validation loss eğrileri.

SBERT öznitelikleri kullanılarak eğitilen modellerin eğitim sürecindeki yakınsama davranışları Şekil 4.4, 4.5 ve 4.6’da sunulmuştur. Eğitim süreci kapsamında, her 50 adımda bir validasyon kaybı (validation loss) hesaplanmış ve her model için bu değerin


en düşük olduđu adımdaki ağırlıklar kaydedilmiştir. Elde edilen bulgulara göre; Qwen3-4B modeli 350. adımda 0,4110, Qwen2.5-3B modeli 350. adımda 0,4985 ve OpenLLaMA-3B modeli 350. adımda 0,4359 değerleriyle en düşük validasyon kaybına ulaşmıştır.



Şekil 4.4. Qwen3-4B-Instruct modelinin SBERT öznitelikleri eklenmiş veri setiyle 500 adımlık eğitim sürecine ait train ve validation loss eğrileri.



Şekil 4.5. Qwen2.5-3B-Instruct modelinin SBERT öznitelikleri eklenmiş veri setiyle 500 adımlık eğitim sürecine ait train ve validation loss eğrileri.



Şekil 4.6. OpenLLaMA-3B modelinin SBERT öznitelikleri eklenmiş veri setiyle 500 adımlık eğitim sürecine ait train ve validation loss eğrileri.

4.2. BULGULARIN ANALİZİ

Çizelge 4.1 ve Çizelge 4.2'de sunulan sonuçlar, ince ayar sürecinin ve SBERT özniteliklerinin model performansı üzerindeki etkisini açıkça ortaya koymaktadır.

4.2.1. İnce ayarın etkisi (RQ1)

Her üç modelde de ve her iki senaryoda da ince ayar uygulaması; test kaybı ve perplexity değerlerinde belirgin bir düşüş, BERTScore F1 değerlerinde ise belirgin bir artış sağlamıştır. SBERT'siz koşulda test kayıpları Qwen3-4B için 1,9098'den 1,2711'e, Qwen2.5-3B için 2,2089'dan 1,6739'a ve OpenLLaMA-3B için 2,1075'ten 1,4531'e gerilemiştir. Buna paralel olarak format uyumu da ince ayar sonrasında çarpıcı biçimde artmış; hem SBERT'li hem de SBERT'siz koşullarda Qwen3-4B ve Qwen2.5-3B modelleri 199/199 oranında tam format uyumu sağlamıştır. BERTScore F1 değerlerindeki artış ise modellerin ince ayar sonrasında referans cevaplarla anlamsal örtüşmeyi daha başarılı biçimde yakaladığına işaret etmektedir. Hem OpenLLaMA-3B

modelinin hiç geçerli çıktı üretememiş olması (geçerli örnek = 0), LoRA tabanlı ince ayarın görev formatını öğrenmede kritik bir rol oynadığını açıkça ortaya koymaktadır. MAE değerleri yalnızca geçerli formatta çıktı üretilen örnekler üzerinden hesaplandığından, ince ayarın puan tahmini doğruluğu üzerindeki etkisini kesin bir dille değerlendirmek güçtür. Bununla birlikte mevcut bulgular, 12 farklı cevap senaryosunu kapsayan dengeli veri seti tasarımının modelin yapılandırılmış çıktı formatını içselleştirmesine katkı sağladığını ve perplexity değerlerindeki düşüşün modelin çıktı üretim sürecinde daha az belirsizlik yaşadığına işaret ettiğini ortaya koymaktadır.

4.2.2. SBERT özniteliklerinin etkisi (RQ2)

SBERT özniteliklerinin etkisi, ince ayar uygulanmamış ve uygulanmış modeller için ayrı ayrı değerlendirilmiştir. İnce ayar uygulanmamış modeller karşılaştırıldığında, SBERT özniteliklerinin eklenmesi genel olarak test kaybı ve perplexity değerlerini yükseltmiş, BERTScore F1 değerlerini düşürmüştür; buna karşın format uyumunu iyileştirmiştir. Bu koşulda MAE değerleri üzerine kesin bir yorum yapmak güçtür; zira OpenLLaMA-3B geçerli formatta çıktı üretemezken Qwen3-4B'de MAE düşüş, Qwen2.5-3B'de ise yükseliş gözlemlenmiştir. İnce ayar uygulanmış modeller karşılaştırıldığında ise tablo belirgin biçimde değişmektedir. SBERT özniteliklerinin eklenmesi test kaybı ve perplexity değerlerini düşürmüştür, format uyumunu ve MAE değerlerini büyük ölçüde iyileştirmiştir. BERTScore F1 açısından ise ince ayarlı modeller arasında yalnızca Qwen3-4B istisnai bir durum sergilemiş; SBERT'siz koşulda 0,5285 olan F1 değeri SBERT'li koşulda 0,5198'e gerilemiştir. Diğer iki modelde ise bu değerde yükseliş gözlemlenmiştir. MAE değerleri incelendiğinde, ince ayarlı Qwen3-4B modelinde 0,2395'ten 0,1635'e, OpenLLaMA-3B'de ise 0,3074'ten 0,1928'e gerileme sağlanmış; OpenLLaMA-3B'nin format uyumu da 47'den 181'e yükselmiştir. Bu bulgular, simQS ve simSC skorlarının modele anlamsal bir referans noktası sunarak hem puan tahmin doğruluğunu hem de referans cevaplarla anlamsal örtüşmeyi genel olarak iyileştirdiğine işaret etmektedir. Yakınsama eğrileri

incelendiğinde de bu etki gözlemlenmekte; SBERT'siz koşulda Qwen3-4B için en iyi validasyon kaybı 0,46186 iken SBERT'li koşulda 0,4110'a gerilemiş, Qwen2.5-3B ve OpenLLaMA-3B modellerinde de benzer iyileşmeler gözlemlenmiştir.

4.2.3. BERTScore karşılaştırması

Metin kalitesi açısından değerlendirildiğinde, SBERT'li modellerin ince ayarlı versiyonlarının BERTScore F1 değerleri SBERT'siz muadillerine kıyasla genel olarak daha düşük seyretmiştir. İnce ayarlı Qwen3-4B modelinde SBERT'siz koşulda F1 0,5285 iken SBERT'li koşulda 0,5198'e gerilemiştir. Öte yandan Recall değerleri SBERT'li koşulda daha yüksek çıkmış; bu durum, SBERT özniteliklerinin modeli referans cevabı daha kapsamlı biçimde karşılamaya yönelttiğini ancak bunu kısmen hassasiyet pahasına gerçekleştirdiğine işaret etmektedir.

4.2.4. Model karşılaştırması (RQ3)

Benzer parametre sayısına sahip modeller arasında Qwen3-4B-Instruct, büyük çoğunlukla tüm koşullarda en iyi performansı sergilemiştir. SBERT'li ince ayarlı koşulda Qwen3-4B; MAE 0,1635, BERTScore F1 0,5198 ve tam format uyumu (199/199) ile Qwen2.5-3B ve OpenLLaMA-3B modellerinin önünde yer almıştır. Bu üstünlüğün yalnızca model boyutundan değil, Qwen3 mimarisinin daha gelişmiş instruction-following kapasitesine ve daha güncel ön eğitim verisiyle desteklenmesine bağlı olduğu değerlendirilmektedir. OpenLLaMA-3B'nin ham koşulda hiç geçerli çıktı üretememiş olması ve SBERT'li ince ayar sonrasında dahi format uyumunun 181'de kalması, instruction-tuning altyapısının otomatik cevap değerlendirmesi görevleri için belirleyici bir etken olduğunu ortaya koymaktadır. Bununla birlikte OpenLLaMA-3B'nin, instruction-tuning altyapısından yoksun olmasına karşın SBERT'li ince ayar sonrasında 181 geçerli çıktı üretmesi ve MAE değerinde 0,1928 ile Qwen2.5-3B modelini geride bırakması dikkat çekici bir bulgudur. Bu durum,

simQS ve simSC gibi anlamsal özniteliklerin instruction-tuning eksikliğini kısmen telafi edebildiğine ve model altyapısından bağımsız olarak puanlama başarısına katkı sağlayabildiğine işaret etmektedir.

4.2.5. Tutarlılık ve pratik kullanılabilirlik (RQ4)

Format uyumu, otomatik puanlama sisteminin pratik kullanılabilirliği açısından kritik bir gösterge niteliği taşımaktadır. Qwen3-4B ve Qwen2.5-3B'nin ince ayar sonrasında her iki koşulda da 199/199 oranında geçerli çıktı üretmesi, bu modellerin gerçek sınıf ortamında tutarlı ve güvenilir biçimde çalışabilme potansiyeli olduğuna işaret etmektedir. MAE değerlerinin 0,16-0,21 aralığında seyretmesi, modelin öğrenci cevaplarını 0-1 puan aralığında değerlendirdiği göz önüne alındığında kabul edilebilir bir hata payına karşılık gelmekte ve sistemin manuel değerlendirme süreçlerindeki iş yükünü hafifletme potansiyeli taşıdığını ortaya koymaktadır.

BÖLÜM 5

SONUÇLAR VE ÖNERİLER

Bu çalışma, düşük parametrelili açık kaynaklı Büyük Dil Modellerinin (LLM) eğitim teknolojilerinde, özellikle teknik terminoloji içeren açık uçlu soruların otomatik değerlendirilmesinde etkin biçimde kullanılabileceğini potansiyel olarak ortaya koymuştur. Hücre zarı ve taşıma mekanizmaları, hücre organelleri, enerji metabolizması, genetik moleküller, protein sentezi ve hücre bölünmesi konularını kapsayan 1116 örneklik veri seti; tam doğru, eksik, ters bilgi içeren, yüzeysel ve kaçamak cevap dahil 12 farklı senaryo gözetilerek dengeli biçimde tasarlanmış ve SBERT öznitelikleri kullanılarak ince ayar uygulanmış modellerin ham modellerle kıyaslandığında hem format tutarlılığı hem de puanlama doğruluğu açısından belirgin üstünlük sergilediği deneysel olarak gösterilmiştir.

LoRA tabanlı ince ayar sürecinin en çarpıcı sonucu format uyumu üzerinde gözlemlenmiştir. Ham koşulda hiçbir geçerli çıktı üretemeyen OpenLLaMA-3B modeli, SBERT'li ince ayar sonrasında 181/199 format uyumu ve 0,1928 MAE değerine ulaşmıştır. Qwen3-4B-Instruct modeli ise her iki koşulda da tam format uyumu (199/199) sağlamış ve SBERT'li ince ayarlı koşulda 0,1635 MAE değeriyle en yüksek puanlama doğruluğuna ulaşmıştır. Bu üstünlüğün Qwen3 mimarisinin gelişmiş instruction-following kapasitesine ve daha güncel ön eğitim verisiyle desteklenmesine bağlı olduğu değerlendirilmektedir.

SBERT tabanlı simQS ve simSC özniteliklerinin sisteme entegre edilmesi, ince ayar uygulanmış modellerde MAE değerlerini ve format uyumunu genel olarak iyileştir-

miřtır. Özellikle instruction-tuning altyapısından yoksun OpenLLaMA-3B modelinin SBERT  znitelikleriyle desteklenerek Qwen2.5-3B modelini MAE aısından geride bırakması, anlamsal  zniteliklerin model altyapısındaki eksiklikleri kısmen telafi edebildiğini ortaya koymaktadır. Yakınsama eđrileri de bu bulguyu destekler nitelikte olup SBERT'li kořulda t m modellerde daha d ř k validasyon kaybı deđerlerine ulařılmıřtır.

MAE deđerlerinin 0-1 puanlık  lekte 0,16-0,21 aralıęında seyretmesi ve ince ayarlı modellerin b y k ođunluęunun tam format uyumu saęlaması, geliřtirilen sistemin gerek sınıf ortamında manuel deđerlendirme s relerindeki iř y k n  hafifletme potansiyeli tařıdığını g stermektedir.

Gelecek alıřmalarda veri setinin farklı disiplinleri kapsayacak biimde geniřletilmesi, olası ařır   đrenme etkisinin azaltılması ve daha b y k parametrelili modellerle karřılařtırmalı deđerlendirme yapılması hedeflenmektedir. Bunun yanı sıra OCR bileřeninin el yazısı tanımayı destekler hale getirilmesi, sistemin pratik kullanılabilirliğini daha da artıracaktır.

KAYNAKLAR

- AlGhamdi, E. M., Li, Y., Gašević, D., & Chen, G. (2026). Leveraging prompt-based LLMs for automated scoring and feedback generation in higher education. *Computers & Education*, 243, 105511. <https://doi.org/10.1016/j.compedu.2025.105511>
- Arffman, I. (2016). Threats to validity when using open-ended items in international achievement studies: Coding responses to the PISA 2012 problem-solving test in Finland. *Scandinavian Journal of Educational Research*, 60(6), 609–625. <https://doi.org/10.1080/00313831.2015.1066429>
- Atkinson, J., & Palma, D. (2025). An LLM-based hybrid approach for enhanced automated essay scoring. *Scientific Reports*, 15(1). <https://doi.org/10.1038/s41598-025-87862-3>
- Bloom, B. S., Engelhart, M. D., Furst, E. J., Hill, W.H., & Krathwohl, D. R. (1956). *Taxonomy of educational objectives: The classification of educational goals. Handbook I*. McKay.
- Can, E. (t.y.). *bert-base-turkish-cased-mean-nli* [Model]. Hugging Face. <https://huggingface.co/emrean/bert-base-turkish-cased-mean-nli>
- Cullen, R. (1998). Teacher talk and the classroom context. *ELT Journal*, 52(3), 179–187. <https://doi.org/10.1093/elt/52.3.179>
- Feng, Z. (2014). Using Teacher Questions to Enhance EFL Students' Critical Thinking Ability. *Journal of Curriculum and Teaching*, 2(2). <https://doi.org/10.5430/jct.v2n2p147>
- Geng, X., & Liu, H. (2023). *OpenLLaMA: An open reproduction of LLaMA* [Computer software]. GitHub. https://github.com/openlm-research/open_llama
- Greenfield, D. B., Jirout, J., Dominguez, X., Greenberg, A., Maier, M., & Fuccillo, J. (2009). Science in the preschool classroom: A programmatic research agenda to improve science readiness. *Early Education & Development*, 20(2), 238–264.
- Heydari, A., Alkendi, S., & Eetemadi, S. (2026). AI-Based Automated Grading of Short Answer Responses with Interactive Feedback. *Procedia Computer Science*, 275, 716–723. <https://doi.org/10.1016/j.procs.2026.01.083>
- Hou, Z. J., Ciuba, A., & Li, X. L. (2025). *Improve LLM-based Automatic Essay Scoring with Linguistic Features*. <http://arxiv.org/abs/2502.09497>
- Kwon, O. N., Park, J. H., & Park, J. S. (2006). Cultivating divergent thinking in mathematics through an open-ended approach. *Asia Pacific Education Review*, 7(1), 51–61.
- Lee, J. X., & Song, Y. T. (2024). College Exam Grader using LLM AI models. *27th IEEE/ACIS International Summer Conference on Software Engineering Artificial Intelligence Networking and Parallel/Distributed Computing, SNPD 2024 - Proceedings*, 282–289. <https://doi.org/10.1109/SNPD61259.2024.10673924>

- Livingston, S. A. (2009). *Constructed-Response Test Questions: Why We Use Them; How We Score Them*.
- Pack, A., Barrett, A., & Escalante, J. (2024). Large language models and automated essay scoring of English language learner writing: Insights into validity and reliability. *Computers and Education: Artificial Intelligence*, 6. <https://doi.org/10.1016/j.caeai.2024.100234>
- Polanko, E. F. J. (2025). *LLM Agent for Essay Scoring: Essay Scoring with Different Prompt Techniques and Open Source LLM Models* [Master's thesis, Ural Federal University]. <https://elar.urfu.ru/handle/10995/147598>
- Qwen Team. (2025). *Qwen2.5 technical report*. arXiv. <https://doi.org/10.48550/arXiv.2412.15115>
- Qwen Team. (2025). *Qwen3 technical report*. arXiv. <https://doi.org/10.48550/arXiv.2505.09388>
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, 3982–3992. <https://arxiv.org/abs/1908.10084>
- Stahl, M., Biermann, L., Nehring, A., & Wachsmuth, H. (2024). *Exploring LLM Prompting Strategies for Joint Essay Scoring and Feedback Generation*. <https://github.com/webis-de/BEA-24>.
- Smith, R. (2007). An overview of the Tesseract OCR engine. *Proceedings of the Ninth International Conference on Document Analysis and Recognition (ICDAR 2007)*, 2, 629–633. <https://doi.org/10.1109/ICDAR.2007.4376991>
- Xiao, C., Ma, W., Song, Q., Xu, S. X., Zhang, K., Wang, Y., & Fu, Q. (2025). Human-AI Collaborative Essay Scoring: A Dual-Process Framework with LLMs. *15th International Conference on Learning Analytics and Knowledge, LAK 2025*, 293–305. <https://doi.org/10.1145/3706468.3706507>
- Yavuz, F., Çelik, Ö., & Yavaş Çelik, G. (2025). Utilizing large language models for EFL essay grading: An examination of reliability and validity in rubric-based assessments. *British Journal of Educational Technology*, 56(1), 150–166. <https://doi.org/10.1111/bjet.13494>
- Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2020). BERTScore: Evaluating text generation with BERT. *Proceedings of the 8th International Conference on Learning Representations (ICLR 2020)*. <https://doi.org/10.48550/arXiv.1904.09675>

ÖZGEÇMİŞ

Umut Toprak AKTÜRK, 2003 yılında Ankara’da doğdu. İlk ve ortaöğrenimini Kırıkkale’de tamamladı. 2017 yılında başladığı Ankara Gdl Hasan Hseyin Akdede Fen Lisesi’nden 2021 yılında mezun oldu. Aynı yıl Karabk niversitesi Mhendislik Fakltesi Bilgisayar Mhendislięi Blm’nde lisans eęitimine başladı. Halen aynı kurumda eęitimine devam etmektedir.

ADRES BİLGİLERİ

Adres : Kardelen Mah. 2037 Cad. Dostlar

Sitesi B Blok Daire : 22 Yenimahalle / ANKARA

Tel : (541) 3810361

E-posta : toprak.akturk765@gmail.com